

보충 자료

기초 선형대수 및 확률

* 전체 내용을 다루는게 아닌, 강의에 필요한 부분만 다루겠습니다.
자세히 설명하지 않은 부분은 “아 이렇게 있구나~” 하고 넘어가시면 됩니다.

강사 최윤희

{

선형대수

}

Scalars (스칼라)

- 스칼라는 하나의 숫자
- 정수, 실수, 유리수 등
- 이탤릭체로 표시합니다.

a, n, x

Vectors (벡터)

- 벡터는 숫자들의 1-D array (소문자, 볼드체로 표시)

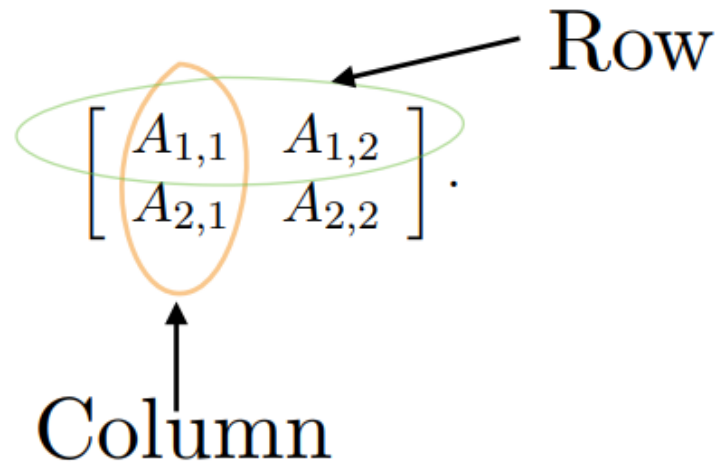
$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} .$$

- 실수, binary (0 또는 1), 정수 등 일 수 있음
- n차원의 실수 벡터의 집합을 다음과 같이 나타냄

$$\mathbb{R}^n$$

Matrices (행렬)

- 행렬은 숫자들의 2-D array



A diagram illustrating a 2x2 matrix A . The matrix is represented as $\begin{bmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \end{bmatrix}$. A green oval encircles the entire matrix, with an arrow pointing to it from the label "Row". An orange oval encircles the first column, with an arrow pointing to it from the label "Column".

- A 라는 행렬 (대문자, 볼드체로 표시)이 m 개의 row (행), n 개의 column (열)을 가지고 있다는 것을 다음과 같이 나타냄:

$$\mathbf{A} \in \mathbb{R}^{m \times n}$$

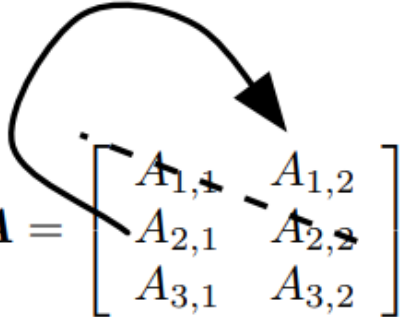
Tensors (텐서)

- 텐서는 숫자들의 array인데,
 - 0차원의 스칼라일 수도 있고
 - 1차원의 벡터일 수도 있고,
 - 2차원의 행렬일 수도 있고
 - n차원의 array일 수도 있음.

Matrix Transpose (전치)

- 행이 열로 가도록, 열이 행으로 가도록 함. (주대각선 ($i=j$)에 거울처럼 반사 시킨다고 생각해도 됨)

$$(\mathbf{A}^T)_{i,j} = A_{j,i}.$$



$$\mathbf{A} = \begin{bmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \\ A_{3,1} & A_{3,2} \end{bmatrix} \Rightarrow \mathbf{A}^T = \begin{bmatrix} A_{1,1} & A_{2,1} & A_{3,1} \\ A_{1,2} & A_{2,2} & A_{3,2} \end{bmatrix}$$


- 행렬 곱의 전치

$$(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T$$

Matrix Product (행렬 곱)

$$C = AB.$$

$$C_{i,j} = \sum_k A_{i,k} B_{k,j}.$$



Matrix Product (행렬 곱)

$$A(B + C) = AB + AC.$$

$$A(BC) = (AB)C.$$

$$AB \neq BA$$

Identity Matrix (단위 행렬)

- 주 대각선의 성분 ($i=j$)이 1, 나머지는 0인 정사각행렬 ($m=n$)

$$\mathbf{I}_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- 단위행렬은 어떤 벡터를 곱해도 해당 벡터를 변형시키지 않음

$$\forall \mathbf{x} \in \mathbb{R}^n, \mathbf{I}_n \mathbf{x} = \mathbf{x}.$$

Systems of Equations (선형 방정식 계)

- m 개의 선형 방정식을 아래와 같이 행렬 곱을 이용하여 나타낼 수 있음. (세미콜론: slicing)

$$Ax = b$$

expands to

$$A_{1,:}x = b_1$$

$$A_{2,:}x = b_2$$

...

$$A_{m,:}x = b_m$$

Systems of Equations (선형 방정식 계)

- 선형 방정식 계는
 - 해가 없을 수도 있고
 - 여러 개 일수도 있고
 - 하나의 해만 존재할 수도 있음. (행렬 A 의 역행렬이 존재할 때)

Matrix Inversion (역행렬)

- 역행렬: 원행렬에 곱했을 때 단위행렬이 되는 행렬

$$A^{-1}A = I_n$$

- 이를 통해 선형 방정식 계를 해결

$$Ax = b$$

$$A^{-1}Ax = A^{-1}b$$

$$I_n x = A^{-1}b$$

- 역행렬이 존재하지 않는 경우
 - 열이 행보다 많거나, 행이 열보다 많거나
 - 서로 비슷한 행/열들을 가지고 있을 때 (용어: 선형 종속) (선형 독립이어야 역행렬 존재!)

Norms

- 벡터가 얼마나 큰지 나타내는 함수: zero vector와의 거리로 볼 수도 있음

- L^p norm

$$||\mathbf{x}||_p = \left(\sum_i |x_i|^p \right)^{\frac{1}{p}}$$

- Most popular norm: L2 norm, $p=2$
- L1 norm, $p=1$: $||\mathbf{x}||_1 = \sum_i |x_i|$.
- Max norm, infinite p : $||\mathbf{x}||_\infty = \max_i |x_i|$.

특별한 성질의 행렬과 벡터

- Unit vector (단위 벡터)

$$||\boldsymbol{x}||_2 = 1.$$

- 대칭행렬

$$\boldsymbol{A} = \boldsymbol{A}^\top.$$

- 직교 행렬

$$\boldsymbol{A}^\top \boldsymbol{A} = \boldsymbol{A} \boldsymbol{A}^\top = \boldsymbol{I}.$$

$$\boldsymbol{A}^{-1} = \boldsymbol{A}^\top$$

Eigendecomposition (고윳값 분해)

- $n \times n$ 행렬 A 의 고윳값 λ 와 고유벡터 v 의 정의

$$Av = \lambda v.$$

- 각각 n 개의 고윳값과 고유벡터를 얻었을 때, $Av_i = \lambda_i v_i$ for $i = 1, 2, \dots, n$

$$V = \begin{bmatrix} | & | & \cdots & | \\ v_1 & v_2 & \cdots & v_n \\ | & | & \cdots & | \end{bmatrix} \in \mathbb{R}^{n \times n}$$

$$AV = \begin{bmatrix} | & | & \cdots & | \\ \lambda_1 v_1 & \lambda_2 v_2 & \cdots & \lambda_n v_n \\ | & | & \cdots & | \end{bmatrix}$$

- $\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & 0 & 0 \\ & & \ddots & \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$


라고 하면 맨 위의 정의를 다음과 같이 쓸 수 있다.

$$AV = V\Lambda$$

특히 고유벡터들이 선형 독립하다면: $A = V\Lambda V^{-1}$

Eigendecomposition (고윳값 분해)

- 단위 원 위의 단위 벡터들에 행렬 A 를 곱하면, A 의 고유벡터 v 방향으로 각각의 고유값으로 스케일링하는 식으로 공간을 변형함



SVD, Trace, Determinant (Optional)

- Singular Value Decomposition (특이값 분해): 고윳값 분해와 비슷하나 정사각행렬일 필요 없는 더 일반적인 방법.

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^{\top}.$$

- \mathbf{A} : $m \times n$, \mathbf{U} : $m \times m$, \mathbf{D} : $m \times n$, \mathbf{V} : $n \times n$
- Trace (대각합): 주 대각선의 성분을 모두 더한 것.
$$\text{Tr}(\mathbf{A}) = \sum_i \mathbf{A}_{i,i}.$$
$$\text{Tr}(\mathbf{AB}) = \text{Tr}(\mathbf{BA})$$
- Determinant (행렬식): 정사각행렬 \mathbf{A} 의 행렬식 $\det(\mathbf{A})$ 는 스칼라 값으로, \mathbf{A} 의 모든 고윳값들의 곱이다.

}

하
하

}

Random Variable (확률변수, r.v.)

- 확률적으로 다른 값들을 가질 수 있는 변수
- Discrete variable: 셀 수 있는 값들 (불연속) 중 하나를 가질 수 있는 변수. ex) 내일의 강수 여부 X
- Continuous variable: 연속적인 값을 가질 수 있는 변수 ex) 내일의 강수량 Z

PMF, PDF

- Probability Mass Function (확률질량함수): discrete r.v.가 어떤 값을 가질 확률을 계산하는 함수

$$\forall x \in \mathbf{x}, 0 \leq P(x) \leq 1.$$

$$\sum_{x \in \mathbf{x}} P(x) = 1$$

- ex) uniform distribution: $P(\mathbf{x} = x_i) = \frac{1}{k}$

- Probability Density Function (확률밀도함수): continuous r.v.가 어떤 값을 가질 확률을 계산하는 함수

$$\forall x \in \mathbf{x}, p(x) \geq 0$$

$$\int p(x) dx = 1.$$

- ex) 구간 $[a, b]$ 사이의 uniform distribution: $u(x; a, b) = \frac{1}{b-a}$

Marginal Probability

- Sum rule:
 - discrete r.v. :

$$\forall x \in \mathbf{x}, P(\mathbf{x} = x) = \sum_y P(\mathbf{x} = x, y = y).$$

- continuous r.v. :

$$p(x) = \int p(x, y) dy.$$

Conditional Probability

- $X = x$ 가 주어졌을 때, $Y = y$ 일 확률

$$P(Y = y \mid X = x) = \frac{P(Y = y, X = x)}{P(X = x)}.$$

Chain Rule of Probability

- 여러 개의 r.v.에 대한 확률분포가 주어졌을 때 (joint probability), 한 r.v.에 대한 조건부확률들로 이를 분해 가능

$$P(x^{(1)}, \dots, x^{(n)}) = P(x^{(1)}) \prod_{i=2}^n P(x^{(i)} \mid x^{(1)}, \dots, x^{(i-1)}).$$

- 예시

$$P(a, b, c) = P(a \mid b, c)P(b, c)$$

$$P(b, c) = P(b \mid c)P(c)$$

$$P(a, b, c) = P(a \mid b, c)P(b \mid c)P(c).$$

Independence (독립)

- independence (독립): x 와 y 가 독립이라면 아래의 식 성립, 또한 아래의 식 성립하면 x 와 y 는 독립

$$\forall x \in \mathbf{x}, y \in \mathbf{y}, p(x = x, y = y) = p(x = x)p(y = y).$$

- conditional independence: z 가 주어졌을 때 x 와 y 가 조건부 독립, 또한 아래의 식 성립하면 조건부 독립

$$\forall x \in \mathbf{x}, y \in \mathbf{y}, z \in \mathbf{z}, p(x = x, y = y \mid z = z) = p(x = x \mid z = z)p(y = y \mid z = z).$$

Expectation (기댓값)

- Discrete r.v.

$$\mathbb{E}_{\mathbf{x} \sim P}[f(x)] = \sum_x P(x) f(x)$$

- Conditional r.v.

$$\mathbb{E}_{\mathbf{x} \sim p}[f(x)] = \int p(x) f(x) dx$$

- 선형성

$$\mathbb{E}_{\mathbf{x}}[\alpha f(x) + \beta g(x)] = \alpha \mathbb{E}_{\mathbf{x}}[f(x)] + \beta \mathbb{E}_{\mathbf{x}}[g(x)]$$

Variance

- Variance (분산) : 평균(기댓값)에 대해 확률분포가 퍼져있는 정도

$$\text{Var}(f(x)) = \mathbb{E} \left[(f(x) - \mathbb{E}[f(x)])^2 \right]$$

- Covariance (공분산): 두 r.v.의 상관 관계를 알 수 있음 (양수: 양의 상관관계, 음수: 음의 상관관계)

$$\text{Cov}(f(x), g(y)) = \mathbb{E} [(f(x) - \mathbb{E}[f(x)]) (g(y) - \mathbb{E}[g(y)])] .$$

- 공분산 행렬

$$\text{Cov}(\mathbf{x})_{i,j} = \text{Cov}(x_i, x_j).$$

대표적인 확률분포

- 베르누이 분포: x 는 binary random variable로 0 또는 1의 값을 가질 수 있음. $x=1$ 일 확률을 ϕ 라고 했을 때,

$$P(x = 1) = \phi$$

$$P(x = 0) = 1 - \phi$$

$$P(x = x) = \phi^x (1 - \phi)^{1-x}$$

$$\mathbb{E}_x[x] = \phi$$

$$\text{Var}_x(x) = \phi(1 - \phi)$$


- 가우시안 분포: mean과 variance로 parameterized됨.

$$\mathcal{N}(x; \mu, \sigma^2) = \sqrt{\frac{1}{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right).$$

- 다변수 가우시안 분포: mean vector와 covariance matrix로 parameterized됨.

$$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sqrt{\frac{1}{(2\pi)^n \det(\boldsymbol{\Sigma})}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right).$$

가우시안 분포



Bayes' Rule

- 베이즈 룰: 조건부 확률 + 체인 룰

$$P(x \mid y) = \frac{P(x)P(y \mid x)}{P(y)}.$$

정보 이론 (Optional)

- Information Theory

- information: 확률이 낮은 사건이 일어나는 것이 더 유용한 정보임. ex) 해가 동쪽에서 뜬다 → 유용한 정보 X

$$I(x) = -\log P(x).$$

- Entropy: 분포 P에서 얻을 수 있는 정보의 기댓값. 전체 확률 분포에 대한 uncertainty (불확실성)의 양으로 볼 수 있음.

$$H(x) = \mathbb{E}_{x \sim P}[I(x)] = -\mathbb{E}_{x \sim P}[\log P(x)].$$

- KL divergence: 항상 0보다 크고, 두 분포 P와 Q가 같을 때만 0 → 두 분포가 얼마나 다른지 나타낼 때 사용

$$D_{\text{KL}}(P \| Q) = \mathbb{E}_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right] = \mathbb{E}_{x \sim P} [\log P(x) - \log Q(x)].$$